

Modelado supervisado de tasas brutas de mortalidad y natalidad a partir de indicadores socioeconomicos del Banco Mundial

Guillermo Paredes, Donato Oña, Mateo Villacreses, Karla Estefania Moras Cajas
Universidad Internacional del Ecuador (UIDE)
Ecuador

Resumen—Este artículo presenta el desarrollo de un pipeline reproducible de ciencia de datos para modelar las tasas brutas de mortalidad y natalidad de países del mundo entre 2000 y 2022, empleando indicadores socioeconomicos y demograficos del Banco Mundial. El problema se formula como una tarea de regresión supervisada con datos panel país-año. La metodología incluye adquisición reproducible mediante *wbgapi*, filtrado de agregados regionales, imputación jerárquica de valores faltantes, enriquecimiento con estructura etaria, transformaciones logarítmicas, codificación de variables categóricas y validación cruzada agrupada por país para evitar fuga de información. Se compararon cuatro familias de modelos: Ridge, Random Forest, XGBoost y LightGBM. En una ejecución de referencia, XGBoost obtuvo el mejor desempeño para ambos objetivos, con R^2 aproximado de 0.526 para mortalidad y 0.964 para natalidad. El análisis muestra que la natalidad es altamente predecible, aunque parte de su desempeño se explica por una identidad demográfica con el porcentaje de población de 0 a 14 años. La mortalidad, por su parte, presenta un techo predictivo menor debido a su dependencia de estructura etaria, choques sanitarios, conflictos y variables institucionales no incluidas. Se discuten limitaciones metodológicas asociadas al coeficiente de Gini, la naturaleza modelada del *ground truth* y el tratamiento de valores extremos por dominio.

Palabras clave—aprendizaje automático, regresión supervisada, mortalidad, natalidad, Banco Mundial, datos panel, XGBoost, validación cruzada agrupada

I. INTRODUCCION

Las tasas brutas de mortalidad y natalidad constituyen indicadores esenciales para describir la dinámica demográfica de una población. Aunque ambos indicadores se expresan como eventos por cada 1.000 habitantes, responden a procesos sociales y biológicos distintos. La natalidad tiende a relacionarse con variables de desarrollo, urbanización, nivel de ingreso y estructura por edades. La mortalidad, en cambio, puede adoptar patrones no monotónicos: países de bajos ingresos pueden presentar alta mortalidad por causas evitables, mientras que países de altos ingresos pueden mostrar tasas crudas elevadas debido al envejecimiento poblacional.

El objetivo del proyecto es construir y evaluar modelos de aprendizaje automático capaces de estimar las tasas brutas de mortalidad y natalidad a partir de indicadores socioeconomicos y demograficos del Banco Mundial. La pregunta de investigación que guía el trabajo es: *en que medida los indicadores socioeconomicos, complementados con estructura*

etaria, permiten predecir las tasas brutas de mortalidad y natalidad de países no observados durante el entrenamiento.

Se plantea como hipótesis que los modelos no lineales basados en árboles superan a una línea base lineal, especialmente en la predicción de mortalidad, debido a la relación no monótona entre desarrollo, envejecimiento y mortalidad cruda. Para natalidad se espera un desempeño superior, aunque se anticipa que parte de la capacidad predictiva proviene de variables de estructura etaria, particularmente el porcentaje de población entre 0 y 14 años.

La contribución principal del trabajo es doble. Primero, se implementa un pipeline reproducible, documentado y verificable para adquisición, preprocesamiento, modelado y validación. Segundo, se ofrece una lectura metodológica crítica de los resultados, evitando interpretar la importancia de variables como causalidad y explicando las limitaciones de los datos de origen.

II. TRABAJOS RELACIONADOS

El uso de modelos de regresión supervisada en datos tabulares es una práctica ampliamente extendida en problemas socioeconomicos. Ridge Regression representa una línea base lineal regularizada que permite controlar varianza y multicolinealidad [1]. Random Forest introduce ensambles de árboles mediante agregación de modelos entrenados sobre subconjuntos de datos [2]. XGBoost y LightGBM son métodos de *gradient boosting* diseñados para capturar interacciones no lineales con alto desempeño en datos tabulares [3], [4].

En cuanto a interpretabilidad, las importancias por permutación y los valores SHAP permiten analizar la contribución predictiva de las variables sin asumir linealidad [5]. Sin embargo, estas técnicas deben interpretarse con cautela: cuantifican utilidad predictiva, no relaciones causales. En proyectos aplicados, la documentación del uso previsto, los datos, las métricas y las limitaciones resulta fundamental; por ello, el reporte final incorpora una tarjeta de modelo inspirada en prácticas de transparencia en aprendizaje automático [6].

III. MATERIALES Y METODOS

III-A. Fuente de datos

Los datos provienen de World Bank Open Data y World Development Indicators [7]. La adquisición se realiza mediante la librería *wbgapi*, lo que permite reconstruir el dataset sin

versionar archivos pesados. El periodo de analisis comprende los años 2000 a 2022. La unidad de observacion es el par pais-año.

El dataset original de la API incluye paises individuales y agregados regionales, como “World”, “European Union” o regiones continentales. Estos agregados se excluyen porque no representan unidades nacionales comparables. El pipeline filtra entidades con region vacia o no clasificada, evitando que el modelo aprenda patrones mezclados entre paises y agregados.

III-B. Variables

Las variables objetivo son `death_rate` y `birth_rate`, ambas medidas como eventos por cada 1.000 habitantes. Los predictores combinan dimensiones economicas, sociales, demograficas y contextuales. La Tabla I resume el contrato de datos usado por el modelo.

Tabla I
VARIABLES PRINCIPALES DEL MODELO

Grupo	Variables
Objetivos	tasa bruta de mortalidad, tasa bruta de natalidad
Economicas	crecimiento del PIB, PIB per capita logaritmico, Gini, desempleo
Sociales	gasto en salud, gasto en educacion, urbanizacion
Demograficas	poblacion logaritmica, poblacion de 65+ años, poblacion de 0–14 años
Contextuales	region, nivel de ingreso, año normalizado, bandera 2020–2021
Trazabilidad	bandera de imputacion del Gini

III-C. Preprocesamiento

El preprocesamiento se diseño para preservar la trazabilidad del dato y reducir decisiones arbitrarias. Primero, se eliminan observaciones sin alguna variable objetivo, ya que no pueden emplearse en entrenamiento supervisado. Luego se aplica imputacion jerarquica a los predictores: *forward-fill* por pais, *backward-fill* por pais, mediana por region y nivel de ingreso, mediana regional y mediana global. Para el coeficiente de Gini se crea `gini_imputed`, debido a su alta proporcion de valores faltantes.

El PIB per capita y la poblacion total presentan distribuciones sesgadas a la derecha, por lo que se transforman mediante $\log(1+x)$. La region se codifica con variables *one-hot*, mientras que el nivel de ingreso se codifica ordinalmente de acuerdo con la jerarquia LIC, LMC, UMC y HIC. El año se normaliza al intervalo $[0,1]$, y se añade `is_pandemic` para identificar 2020 y 2021 como años de choque global.

El notebook de preprocesamiento genera tres artefactos: un dataset completo `dataset_modelado.parquet`, una particion de entrenamiento `train_processed.parquet` y una particion de prueba `test_processed.parquet`. La particion se realiza por pais para impedir que años de un mismo pais aparezcan simultaneamente en entrenamiento y prueba.

III-D. Modelos evaluados

Se evaluaron cuatro modelos de regresion: Ridge, Random Forest, XGBoost y LightGBM. La evaluacion principal usa `GroupKFold` con cinco pliegues, agrupando por codigo de pais. Este esquema responde a la pregunta de generalizacion hacia paises no observados, y evita fuga de informacion en datos panel.

Las metricas usadas son RMSE, MAE y R^2 . RMSE se reporta en las mismas unidades del objetivo, MAE ofrece una medida robusta de error absoluto promedio, y R^2 permite comparar la proporcion de varianza explicada.

IV. RESULTADOS

IV-A. Comparacion de modelos

La Tabla II resume una ejecucion de referencia del pipeline de modelado. XGBoost obtuvo el menor RMSE para ambos objetivos. En natalidad el desempeño fue alto, con $R^2 \approx 0,964$, mientras que en mortalidad el R^2 fue moderado, aproximadamente 0.526. Esta diferencia respalda la hipotesis inicial: la mortalidad cruda es mas dificil de aproximar porque combina condiciones de desarrollo con envejecimiento y choques especificos de cada pais.

IV-B. Ablacion de estructura etaria

Para distinguir señal socioeconomica de identidad demografica, se entreno XGBoost con y sin las variables `pop_0to14_pct` y `pop_65plus_pct`. La Tabla III muestra que eliminar estructura etaria afecta ambos objetivos, pero especialmente la natalidad. El R^2 de natalidad cae de 0.964 a 0.809, lo que confirma que el alto desempeño no debe interpretarse como una explicacion puramente socioeconomica. En mortalidad, la caida de 0.526 a 0.320 evidencia que el envejecimiento poblacional es un componente central para explicar la tasa cruda.

IV-C. Importancia de variables

La importancia por permutacion sugiere que `pop_0to14_pct` domina la prediccion de natalidad, seguida por estructura etaria complementaria y variables temporales. Para mortalidad, `pop_65plus_pct` y el PIB per capita logaritmico aparecen entre las variables mas informativas. Esta lectura es coherente con la demografia: la natalidad reciente queda reflejada en la proporcion de menores, mientras que la mortalidad cruda aumenta en poblaciones envejecidas, incluso en paises de altos ingresos.

V. DISCUSION

Los resultados muestran que la formulacion del problema como regresion supervisada es adecuada, pero tambien revelan diferencias sustantivas entre los dos objetivos. La natalidad es altamente predecible porque varios indicadores capturan de forma directa o indirecta el regimen demografico de un pais. Sin embargo, la fuerte relacion con `pop_0to14_pct` obliga a comunicar el resultado con cuidado: el modelo no descubre solamente una relacion causal entre desarrollo y natalidad, sino que explota una variable que resume nacimientos recientes.

Tabla II
DESEMPEÑO DE MODELOS EN VALIDACION CRUZADA AGRUPADA POR PAIS

Target	Modelo	RMSE	MAE	R ²
death_rate	Ridge	2.320	1.576	0.502
death_rate	Random Forest	2.393	1.442	0.469
death_rate	XGBoost	2.252	1.358	0.526
death_rate	LightGBM	2.274	1.374	0.519
birth_rate	Ridge	2.479	1.860	0.947
birth_rate	Random Forest	2.175	1.517	0.959
birth_rate	XGBoost	2.061	1.436	0.964
birth_rate	LightGBM	2.077	1.448	0.963

Tabla III
ABLACION DE VARIABLES DE ESTRUCTURA ETARIA CON XGBOOST

Target	Features	RMSE	R ²
death_rate	con edad	2.252	0.526
death_rate	sin edad	2.698	0.320
birth_rate	con edad	2.061	0.964
birth_rate	sin edad	4.661	0.809

La mortalidad presenta mayor complejidad. El R^2 moderado no necesariamente implica un modelo deficiente; mas bien refleja que la tasa bruta de mortalidad depende de factores no incluidos en el dataset, como conflictos, epidemias, violencia, calidad institucional, cobertura sanitaria, vacunacion, registro civil y eventos extremos. Los residuales mas grandes, segun el analisis del notebook de modelado, tienden a concentrarse en paises o años con dinamicas atipicas, lo que sugiere que la inclusion de variables institucionales y sanitarias podria mejorar el desempeño.

Existen tres consideraciones metodologicas centrales. Primero, el indicador de Gini usado por el Banco Mundial mide desigualdad de ingresos o consumo, no desigualdad sanitaria, de genero ni de acceso a servicios. Segundo, las tasas demograficas publicadas por organismos internacionales no son registros civiles crudos homogeneos, sino estimaciones modeladas a partir de censos, encuestas y sistemas de registro de calidad variable. Tercero, los valores extremos deben analizarse por dominio: una natalidad alta puede ser plausible, una recesion economica puede producir crecimiento negativo valido, y una poblacion muy grande no debe eliminarse como error por criterios IQR uniformes.

VI. CONCLUSIONES

El proyecto implemento un pipeline reproducible para modelar tasas brutas de mortalidad y natalidad con datos del Banco Mundial. La validacion agrupada por pais permite evaluar generalizacion hacia paises no observados, reduciendo fuga de informacion propia de datos panel.

Los resultados respaldan parcialmente la hipotesis planteada. Los modelos no lineales, en particular XGBoost, ofrecen el mejor desempeño global. La mejora es mas relevante en mortalidad, donde la relacion con el desarrollo es no lineal y esta mediada por estructura etaria. La natalidad alcanza valores altos de R^2 , aunque su interpretacion debe matizarse por la

influencia de la estructura etaria, especialmente el porcentaje de poblacion de 0 a 14 años.

Como trabajo futuro se recomienda incorporar variables de gobernanza, capacidad sanitaria, violencia, conflicto, vacunacion y calidad del registro civil. Tambien seria pertinente evaluar una particion temporal si el objetivo cambia de comparacion entre paises a proyeccion demografica. Finalmente, se recomienda profundizar el analisis SHAP por region y nivel de ingreso para explicar heterogeneidad local en las predicciones.

AGRADECIMIENTOS

Los autores agradecen a la Universidad Internacional del Ecuador por el espacio academico para el desarrollo del proyecto interdisciplinario. Se agradece tambien a la docente coautora por su acompañamiento metodologico durante el proceso de investigacion.

REFERENCIAS

- [1] A. E. Hoerl and R. W. Kennard, "Ridge regression: Biased estimation for nonorthogonal problems," *Technometrics*, vol. 12, no. 1, pp. 55–67, 1970.
- [2] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [3] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.
- [4] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [5] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [6] M. Mitchell, S. Wu, A. Zaldivar, P. Barnes, L. Vasserman, B. Hutchinson, E. Spitzer, I. D. Raji, and T. Gebru, "Model cards for model reporting," in *Proceedings of the Conference on Fairness, Accountability, and Transparency*, 2019, pp. 220–229.
- [7] World Bank, "World Development Indicators," <https://databank.worldbank.org/source/world-development-indicators>, 2024, accessed: 2026-06-21.